

עבודת בית בקורס עיבוד תמונות ביו-רפואיות

Image Segmentation

מגיש: גור חנן 025502964

השיטות שבחרתי לבחון הן:

Edge-based segmentation

Region-based segmentation

Clustering-based segmentation

1. תיאור והשוואת השיטות

a. Edge-based segmentation

- i. **תיאור השיטה:** שיטה זו מבוססת על זיהוי גבולות בין אובייקטים על ידי איתור שינוי חד בין הערכים. השיטה מתבססת על חישוב הגרדיאנט וזיהוי השינוי בערכי הפיקסלים לאורך כיוון מסוים. קווים בעלי גרדיאנט גבוה מייצגים גבולות בין אובייקטים.
- ii. **יתרונות:**
 - שיטה פשוטה ליישום
 - יעילה מאוד כאשר קיימים גבולות ברורים בין האובייקטים
- iii. **חסרונות**
 - מסובכת מבחינה חישובית
 - השיטה רגישה לרעש וטשטוש בתמונה
 - קיים קושי בהתמודדות עם גבולות לא ברורים
- iv. **יישום בו משתמשים בשיטה זו:** איתור גידולים בתמונות רפואיות

b. Region-based segmentation

- i. **תיאור השיטה:** שיטה זו מבוססת על קיבוץ פיקסלים דומים לקבוצות. בשיטה זו הדמיון בין הפיקסלים נקבע על סמך צבע, בהירות או תכונות דומות בין הפיקסלים. שיטות מימוש לדוגמה:
 - Region Growing – מתחילים מפיקסל בודד (seed) ובאופן איטרטיבי מתרחבים כלפי חוץ על ידי הוספת פיקסלים דומים.
 - Split and Merge – מחלקים את התמונה לרשת של אזורי קטנים, ואז מצרפים איזורים בעלי תכונות דומות.
- ii. **יתרונות:**
 - פחות רגיש לרעש בתמונה
 - התמודדות טובה עם גבולות מטושטשים ולא ברורים בין אובייקטים

iii. חסרונות:

- מורכבת יותר ליישום (ביחס ל edge)
 - תלויה בבחינה נכונה של מאפייני איחוד הפיקסלים
- iv. יישום בו משתמשים בשיטה זו: ניתוח תמונות לוויין למשל לסיווג שימושי קרקע

c. Clustering-based segmentation

i. **תיאור השיטה:** חלוקת הפיקסלים לקבוצות כך שהפיקסלים בתוך הקבוצה דומים ככל האפשר זה לזה, ופיקסלים בין הקבוצות שונים ככל האפשר זה מזה. זוהי שיטה איטרטיבית שעבור כל פיקסל משייכת אותו לקבוצה הדומה לו ביותר. דוגמאות לשיטות מימוש:

- K-means – חלוקת הנתונים ל K קבוצות (K נקבע על ידי המשתמש) כך שהמרחק הממוצע מכל נקודה בתוך הקבוצה למרכז הקבוצה יהיה מינימלי.
- Mean Shift – שיוך כל נקודה לצבר הנקודות הקרוב ביותר אליו.

ii. יתרונות:

- יעיל בגילוי צורות לא סדורות
- עובד בצורה טובה עם נתונים מרובי מימדים

iii. חסרונות:

- נדרש להגדיר מראש מה מספר הקבוצות (ב K-means)
- רגיש לרעש בתמונה

iv. יישום בו משתמשים בשיטה זו: מעקב אחרי אובייקטים

2. יישום המודלים

בחרתי להשתמש בסט הנתונים של The Berkeley Segmentation Dataset.

מתוך כל המאגר הורדתי 100 תמונות שעליהם הורצו 3 השיטות של הסיגמנטציה שבחרתי, וכמו כן הורדתי את 100 קבצי ה mat שהיוו את ה ground truth לכל תמונה לטובת בחינת תוצאות הרצת הסיגמנטציה בשיטות השונות, וביצוע השוואה בין השיטות.

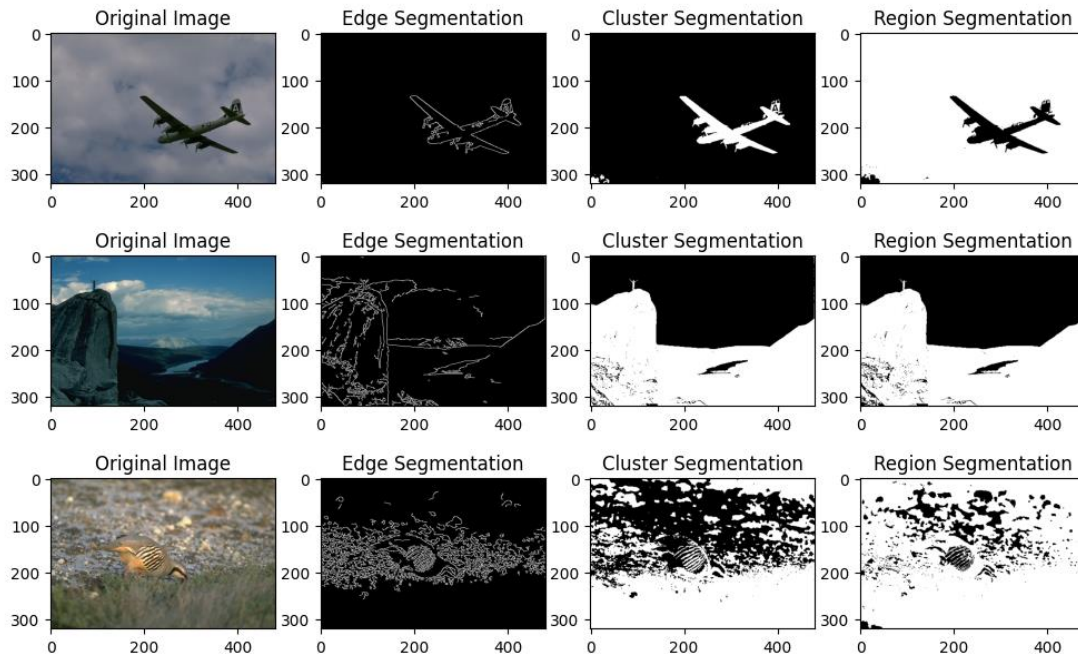
השיטות שנבחרו עבור כל סוג סיגמנטציה:

1. Edge-based segmentation – בחרתי להשתמש ב Canny לזיהוי גבולות האובייקטים שכן זוהי השיטה הפופולארית ביותר ובעלת התוצאות הטובות ביותר (עד שה CNN הרג את קני)
2. Region-based segmentation – השתמשתי בשיטת flood fill שנתנה תוצאות טובות יותר מאשר שיטות אחרות שבדקתי (למשל felzenszwalb)
3. Cluster-based segmentation – השתמשתי בשיטת K-means עם $K=2$. כאשר בחרתי K גדולים יותר, התוצאות שהתקבלו היו פחות טובות.

קוד הפרוייקט נמצא בקובץ ה ipynb המצורף. על מנת להריץ את הקוד, יש ליצור 2 תיקיות: אחת עם התמונות (קבצי jpg) ואחת עם קבצי ה mat כאשר שם התמונה תואם לשם קובץ ה mat שלו, ולהגדיר את הנתיבים לתיקיות אלה.

3. הערכת תוצאות המודלים

במחברת המצורפת, ניתן לראות שאחרי הרצת הקוד מוצגות 5 התוצאות הראשונות של הרצת המודלים (הקובץ המקורי ו 3 תמונות של סוגי הסיגמנטציה שנבחרו):

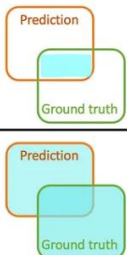


הערכת איכות המודלים בוצעה באמצעות 4 שיטות:

1. Precision – דיוק - מבטא את היחס בין מספר הפיקסלים שהמודל חזה כחיוביים ואכן היו חיוביים (TP) לבין סך כל הפיקסלים שהמודל חזה כחיוביים (TP+FP)
2. Recall - מוכר גם כ *Sensitivity* – מבטא את היחס בין מספר הפיקסלים שהמודל חזה כחיוביים ואכן היו חיוביים (TP) לבין סך כל הפיקסלים החיוביים במקור (TP+FN)
3. Dice – מוכר גם כ F1 score – מבטא את היחס בין פעמיים החיתוך בין ה ground truth לבין החזוי, לבין סך המקרים:

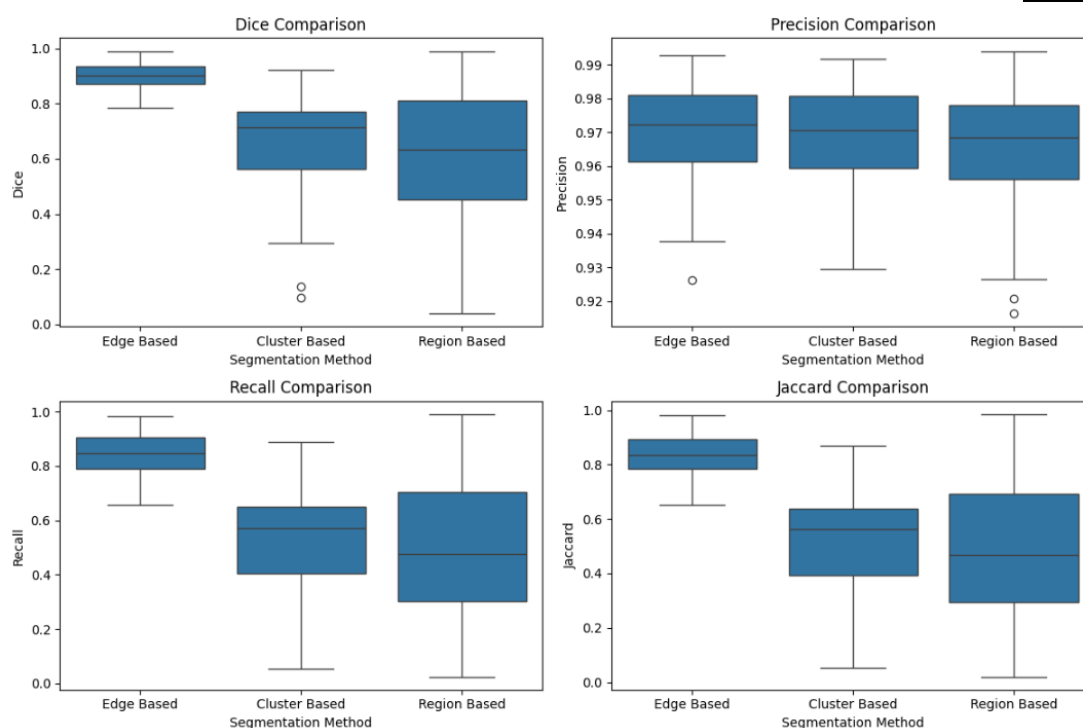
$$\text{Dice} = \frac{2 \times \text{Area of overlap}}{\text{Total area}} = \frac{2 \times \text{Prediction} \cap \text{Ground truth}}{\text{Prediction} \cup \text{Ground truth}}$$

4. Jaccard – מוכר גם כ IoU – Intersect over Union:

$$IoU = \frac{\text{Area of overlap}}{\text{Area of union}} = \frac{\text{Prediction} \cap \text{Ground truth}}{\text{Prediction} \cup \text{Ground truth}}$$


להלן התוצאות שהתקבלו מהשוואת הרצת המודלים על 100 תמונות, וטבלת הנתונים עליהם התבססו הגרפים (ניתן לראות את התוצאות גם במחברת המצורפת):

הגרפים



טבלת הנתונים הגולמיים:

	Image	Method	Dice	Precision	Recall	Jaccard
0	302008.jpg	Edge Based	0.947440	0.966637	0.928990	0.915679
1	302008.jpg	Cluster Based	0.465077	0.960423	0.318023	0.304524
2	302008.jpg	Region Based	0.906596	0.963392	0.857566	0.841660
3	143090.jpg	Edge Based	0.955326	0.974101	0.937261	0.927060
4	143090.jpg	Cluster Based	0.716401	0.966935	0.572419	0.562600
..
295	197017.jpg	Cluster Based	0.562195	0.972571	0.407951	0.393394
296	197017.jpg	Region Based	0.929800	0.967021	0.896834	0.881341
297	42049.jpg	Edge Based	0.948610	0.961450	0.936108	0.920328
298	42049.jpg	Cluster Based	0.876744	0.966426	0.809833	0.791738
299	42049.jpg	Region Based	0.694731	0.947946	0.551376	0.538268

[300 rows x 6 columns]

5. דיון

מהתוצאות שהתקבלו ניתן לראות בצורה די ברורה ש Edge-Based-Segmentation בשיטת Canny נתנו את התוצאות הטובות ביותר בפער ניכר. בכל אחת משיטות ההערכה, הממוצע היה הגבוה ביותר והתפלגות התוצאות היתה עם טווח הערכים הקטן ביותר – כלומר אין פיזור רב של הערכים בניגוד לשיטות האחרות.

בהשוואה בין שיטות הסיגמנטציה האחרות נראה ששיטת Cluster-Based טובה במעט משיטת Region_Based מאחר וברוב המקרים טווח הנתונים מצומצם יותר והחציון גבוה יותר אם כי זה אינו יתרון מובהק ויתכן שבהרצה של מספר גדול מאוד של תמונות המצב ישתנה.

התוצאה הנ"ל אינה מפתיעה שכן שיטת Canny היתה מאוד פופולרית ומוצלחת במציאת גבולות בין אובייקטים וניתן לראות בתמונות במחברת שהשיטה אכן מצליחה לייצג בצורה טובה מאוד את קווי המתאר של האובייקטים בתמונה, בניגוד לשיטת האחרות שהביצועים שלהן פחות טובים.

בעבודה זו האתגר היה במציאת השיטה הטובה ביותר למימוש כל אחת מצורות הסיגמנטציה. לכל קבוצה יש מספר שיטות, והיה נדרש לבחון מספר שיטות עד למציאת השיטה הטובה ביותר לאותו הסוג של הסיגמנטציה.

כפי שניתן לראות בתוצאות ההשוואה, כל שיטה מציגה תוצאות אחרות ובמקרה שלנו ההבדל היה מהותי. עם זאת, יתכן שבסוגים אחרים של ניתוחי צילומים (למשל ניתוח שימושי קרקע מהדמאות לוויין או מעקב אחרי אובייקטים), צורות הסיגמנטציה האחרות יתנו תוצאות טובות יותר, ולכן בכל מקרה של סט נתונים יש לבצע מבחן השוואתי ולבחור את המוצלח ביותר.